Modul 06 - Business Analytics Process and Data Exploration

Roni Yunis

3/26/2021

Pengantar

Dalam pembahasan kali ini, kita akan membahas secara umum proses analisis bisnis dan kaitannya dengan ekplorasi data. Tujuan dari analitika bisnis adalah untuk mendapatkan informasi dari data sehingga dapat membuat keputusan binis yang tepat. Dalam proses analisis bisnis ada beberapa tahapan yang harus dilalui yaitu: 1. Memahami masalah bisnis 2. Mengumpulkan data dan mengintegrasikan data 3. Pra Proses data 4. Ekplorasi dan visualisasi data 5. Menentukan teknik pemodelan atau algaritma 6. Evaluasi model 7. Laporkan hasilnya kepada pihak manajemen 8. Kembangkan model

Dari 8 tahapan tersebut, tahapan yang sangat penting dan berpengaruh pada hasil pengembangan model keputusan adalah tahap **Exploratory Data Analysis (EDA)**. EDA adalah proses ekplorasi data yang bertujuan untuk memahami isi dan komponen penyusun data. Biasanya EDA dilakukan dengan beberapa cara; *analisis deskriptif dengan satu variabel*, *analisis relasi dengan dua variabel*, dan *analisis dengan menggunakan lebih dari atau sama dengan tiga variabel.*

Exploratory Data Analysis (EDA)

Dalam EDA, secara sederhana ada 4 aktivitas yang akan dilakukan, yaitu: menyiapkan data, membersihkan data, Ekplorasi data, dan visualisasi data. Sebelum kita memulai 4 tahapan tersebut, ada beberapa library yang kita perlukan, yaitu `dplyr`, `lubridate` dan `ggplot2`

```
# library yang digunakan untuk data wrangling
library(dplyr)
```

```
##
## Attaching package: 'dplyr'

## The following objects are masked from 'package:stats':
##
##     filter, lag

## The following objects are masked from 'package:base':
##
##     intersect, setdiff, setequal, union
```

```
# library untuk visualisasi data
library(ggplot2)

# library untuk berkerja dengan date
library(lubridate)
```

```
##
## Attaching package: 'lubridate'
```

```
## The following objects are masked from 'package:base':
##
##     date, intersect, setdiff, union
```

Data Preparation

Kita akan import dataset, dataset yang kita gunakan adalah **online_retail.csv**. Kita akan simpan data online retail tersebut kedalam sebuah objek *retail*

```
retail <- read.csv("data/online_retail.csv")
```

Kita akan melihat struktur data dari objek retail dengan fungsi `str()` atau menggunakan fungsi `glimpse()`, fungsi ini merupakan fungsi yang ada pada packages `dplyr`baru kita panggil, dan fungsinya adalah untuk melihat struktur data.

```
# melihat strukturdata dengan glimpse()
glimpse(retail)
```

```
## Rows: 234,920
## Columns: 8
## $ InvoiceNo   <int> 536381, 536381, 536381, 536381, 536381, 536381, 536381,...
## $ StockCode   <chr> "71270", "22262", "22637", "21166", "37444A", "37444C",...
## $ Description <chr> "PHOTO CLIP LINE", "FELT EGG COSY CHICKEN", "PIGGY BANK...
## $ Quantity    <int> 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1...
## $ InvoiceDate <chr> "12/1/10 9:41", "12/1/10 9:41", "12/1/10 9:41", "12/1/1...
## $ UnitPrice   <dbl> 1.25, 0.85, 2.55, 1.95, 2.95, 2.95, 2.95, 0.85, 0.85, 1...
## $ CustomerID  <int> 15311, 15311, 15311, 15311, 15311, 15311, 15311, 15311,...
## $ Country     <chr> "United Kingdom", "United Kingdom", "United Kingdom", "...
```

fungsi dan hasilnya hampir sama dengan fungsi `str()`

```
str(retail)
```

```
## 'data.frame':    234920 obs. of  8 variables:
##  $ InvoiceNo  : int  536381 536381 536381 536381 536381 536381 536381 536381 536381 536381 ...
##  $ StockCode  : chr  "71270" "22262" "22637" "21166" ...
##  $ Description: chr  "PHOTO CLIP LINE" "FELT EGG COSY CHICKEN" "PIGGY BANK RETROSPOT " "COOK WITH WI
##  $ Quantity   : int  1 1 1 1 1 1 1 1 1 1 ...
##  $ InvoiceDate: chr  "12/1/10 9:41" "12/1/10 9:41" "12/1/10 9:41" "12/1/10 9:41" ...
##  $ UnitPrice  : num  1.25 0.85 2.55 1.95 2.95 2.95 2.95 0.85 0.85 1.45 ...
##  $ CustomerID : int  15311 15311 15311 15311 15311 15311 15311 15311 15311 15311 ...
##  $ Country    : chr  "United Kingdom" "United Kingdom" "United Kingdom" "United Kingdom" ...
```

Setelah kita melihat struktur data dari dataset, maka kita akan melihat ringkasan data, untuk melihat apakah ada data yang "Missing Value" atau **NA's**. Kita akan menggunakan fungsi `summary()`

```
summary(retail)
```

```
##    InvoiceNo       StockCode         Description          Quantity
##  Min.   :536365   Length:234920      Length:234920      Min.   :    1.00
##  1st Qu.:541413   Class :character   Class :character   1st Qu.:    1.00
##  Median :546635   Mode  :character   Mode  :character   Median :    3.00
##  Mean   :546827                                        Mean   :   10.51
##  3rd Qu.:552298                                        3rd Qu.:   10.00
##  Max.   :558077                                        Max.   :74215.00
##
##  InvoiceDate          UnitPrice           CustomerID      Country
##  Length:234920      Min.   :    0.000   Min.   :12346   Length:234920
##  Class :character   1st Qu.:    1.250   1st Qu.:13859   Class :character
##  Mode  :character   Median :    2.100   Median :15147   Mode  :character
##                     Mean   :    4.121   Mean   :15283
##                     3rd Qu.:    4.150   3rd Qu.:16818
##                     Max.   :13541.330   Max.   :18287
##                                         NA's   :66245
```

Kalau kita lihat dari hasil diatas ternyata ada data NA's 66245. Sehingga kita harus membersihkan data ini. Untuk menyelesaikan ini, kita akan bahas pada bagian **Clean the Data**

Untuk melihat data yang *missing value* atau NA's juga bisa menggunakan fungsi ini:

```
colSums(is.na(retail))
```

```
##   InvoiceNo   StockCode Description    Quantity InvoiceDate   UnitPrice
##           0           0           0           0           0           0
##  CustomerID     Country
##       66245           0
```

Clean the Data

Membersihkan data NA's

Untuk membersihkan data NA's kita bisa menggunakan fungsi `na.omit()`

```
retail <- na.omit(retail)
summary(retail)
```

```
##    InvoiceNo       StockCode         Description          Quantity
##  Min.   :536365   Length:168675      Length:168675      Min.   :    1.0
##  1st Qu.:542102   Class :character   Class :character   1st Qu.:    2.0
##  Median :547243   Mode  :character   Mode  :character   Median :    6.0
##  Mean   :547309                                        Mean   :   13.3
##  3rd Qu.:552796                                        3rd Qu.:   12.0
##  Max.   :558077                                        Max.   :74215.0
##  InvoiceDate          UnitPrice           CustomerID      Country
##  Length:168675      Min.   :   0.000   Min.   :12346   Length:168675
##  Class :character   1st Qu.:   1.250   1st Qu.:13859   Class :character
##  Mode  :character   Median :   1.950   Median :15147   Mode  :character
```

```
##                     Mean   :   3.286   Mean   :15283
##                     3rd Qu.:   3.750   3rd Qu.:16818
##                     Max.   :8142.750   Max.   :18287
```

Nah kalau kita lihat data yang NA's sudah dihilangkan, sehingga data sudah bersih dan siap untuk dianalisis.

```
glimpse(retail)
```

```
## Rows: 168,675
## Columns: 8
## $ InvoiceNo   <int> 536381, 536381, 536381, 536381, 536381, 536381, 536381,...
## $ StockCode   <chr> "71270", "22262", "22637", "21166", "37444A", "37444C",...
## $ Description <chr> "PHOTO CLIP LINE", "FELT EGG COSY CHICKEN", "PIGGY BANK...
## $ Quantity    <int> 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1...
## $ InvoiceDate <chr> "12/1/10 9:41", "12/1/10 9:41", "12/1/10 9:41", "12/1/1...
## $ UnitPrice   <dbl> 1.25, 0.85, 2.55, 1.95, 2.95, 2.95, 2.95, 0.85, 0.85, 1...
## $ CustomerID  <int> 15311, 15311, 15311, 15311, 15311, 15311, 15311, 15311,...
## $ Country     <chr> "United Kingdom", "United Kingdom", "United Kingdom", "...
```

Merubah type data

Kalau kita perhatikan type data dari InvoiceDate bertype character, kalau kita ingin analisis, maka kita harus rubah type datanya menjadi date atau datetime. Untuk merubah type data kita bisa menggunakan fungsi `mdy()`, fungsi ini ada dalam `library lubridate` yang sebelumnya sudah kita install. Dalam kasus ini, kita juga menggunakan fungsi `mutate()` fungsi ini ada dalam `library dplyr`, fungsi ini gunanya untuk membuat variabel baru yang diturunkan dari variabel yang sudah ada. Dalam kasus ini kita merubah variabel InvoiceDate dari type character ke variabel InvoiceDate dengan type data DateTime.

Objek retail yang sudah dibersihkan kita simpan dalam objek *retailClean*.

```
# Merubah type data InvoiceDate

retailClean <- retail %>%
  mutate(InvoiceDate = mdy_hm(InvoiceDate)) %>%
  arrange(InvoiceDate)
glimpse(retailClean)
```

```
## Rows: 168,675
## Columns: 8
## $ InvoiceNo   <int> 536365, 536365, 536365, 536365, 536365, 536365, 536365,...
## $ StockCode   <chr> "22752", "85123A", "71053", "84029G", "84029E", "21730"...
## $ Description <chr> "SET 7 BABUSHKA NESTING BOXES", "WHITE HANGING HEART T-...
## $ Quantity    <int> 2, 6, 6, 6, 6, 6, 8, 6, 6, 2, 3, 3, 3, 3, 3, 3, 4, 4, 6...
## $ InvoiceDate <dttm> 2010-12-01 08:26:00, 2010-12-01 08:26:00, 2010-12-01 0...
## $ UnitPrice   <dbl> 7.65, 2.55, 3.39, 3.39, 3.39, 4.25, 2.75, 1.85, 1.85, 9...
## $ CustomerID  <int> 17850, 17850, 17850, 17850, 17850, 17850, 17850, 17850,...
## $ Country     <chr> "United Kingdom", "United Kingdom", "United Kingdom", "...
```

Bisa kita lihat bahwa sekarang variabel *InvoiceDate* type datanya sudah berubah menjadi type *datetime (dttm)*

Keterangan: Operator Pipeline atau %>% (dibaca piping) digunakan untuk merangkai beberapa fungsi dalam urutan operasi. Sehingga kita dapat menuliskan lebih dari satu fungsi sekaligus tanpa harus menyimpannya terlebih dahulu. Operator pipeline bisa dibuat dengan cepat menggunakan kombinasi **"ctrl + shift + m"**

Ekplorasi Data

Untuk Ekplorasi data atau prosesd data, bisa disesuaikan dengan kebutuhan. Untuk mendukung hal tersebut kita bisa menggunakan `library dplyr`. Berikut ini beberapa fungsi lain yang ada dalam dplyr yang bisa kita gunakan.

Filter

Fungsi `filter()` digunakan untuk menyeleksi dan menampilkan data sesuai dengan kebutuhan. Misalnya kita ingin memfilter StockCode = 85123A. maka penulisan fungsi filter bisa dilakukan seperti ini. Hasil filter kita simpan dalam objek *stockcode85123A*

```
stockcode85123A <- filter(retailClean, StockCode == "85123A")
head(stockcode85123A)
```

```
##   InvoiceNo StockCode                         Description Quantity
## 1    536365    85123A WHITE HANGING HEART T-LIGHT HOLDER        6
## 2    536373    85123A WHITE HANGING HEART T-LIGHT HOLDER        6
## 3    536375    85123A WHITE HANGING HEART T-LIGHT HOLDER        6
## 4    536390    85123A WHITE HANGING HEART T-LIGHT HOLDER       64
## 5    536394    85123A WHITE HANGING HEART T-LIGHT HOLDER       32
## 6    536396    85123A WHITE HANGING HEART T-LIGHT HOLDER        6
##           InvoiceDate UnitPrice CustomerID        Country
## 1 2010-12-01 08:26:00      2.55      17850 United Kingdom
## 2 2010-12-01 09:02:00      2.55      17850 United Kingdom
## 3 2010-12-01 09:32:00      2.55      17850 United Kingdom
## 4 2010-12-01 10:19:00      2.55      17511 United Kingdom
## 5 2010-12-01 10:39:00      2.55      13408 United Kingdom
## 6 2010-12-01 10:51:00      2.55      17850 United Kingdom
```

Maka bisa dilihat bahwa, semua data akan ditampilkan hanya StockCode = 85123A

Misalnya kita akan memfilter jumlah transaksi hanya dari asal negara United Kingdom pada StockCode 85123A, maka fungsi filter bisa tulis seperti ini.

```
UK <- stockcode85123A %>%
  filter(Country == "United Kingdom")
head(UK)
```

```
##   InvoiceNo StockCode                         Description Quantity
## 1    536365    85123A WHITE HANGING HEART T-LIGHT HOLDER        6
## 2    536373    85123A WHITE HANGING HEART T-LIGHT HOLDER        6
## 3    536375    85123A WHITE HANGING HEART T-LIGHT HOLDER        6
## 4    536390    85123A WHITE HANGING HEART T-LIGHT HOLDER       64
## 5    536394    85123A WHITE HANGING HEART T-LIGHT HOLDER       32
## 6    536396    85123A WHITE HANGING HEART T-LIGHT HOLDER        6
##           InvoiceDate UnitPrice CustomerID        Country
## 1 2010-12-01 08:26:00      2.55      17850 United Kingdom
## 2 2010-12-01 09:02:00      2.55      17850 United Kingdom
## 3 2010-12-01 09:32:00      2.55      17850 United Kingdom
## 4 2010-12-01 10:19:00      2.55      17511 United Kingdom
## 5 2010-12-01 10:39:00      2.55      13408 United Kingdom
## 6 2010-12-01 10:51:00      2.55      17850 United Kingdom
```

Count dan Group By

Fungsi `count()` digunakan untuk mengetahui jumlah data berdasarkan kategori/variabel yang sudah ditentukan sebelumnya. Misalnya dalam kasus ini kita akan hitung jumlah transaksi berdasarkan variabel *Country* yang ada pada objek *stockcode85123A*

```
count(stockcode85123A, Country)
```

```
##            Country    n
## 1        Australia    1
## 2  Channel Islands    1
## 3           Cyprus    3
## 4             EIRE   15
## 5          Finland    1
## 6           France    1
## 7            Malta    1
## 8      Netherlands    4
## 9         Portugal    2
## 10       Singapore    1
## 11           Spain    3
## 12     Switzerland    1
## 13  United Kingdom 1097
```

Group By dan Arrange

Fungsi `group_by()`digunakan untuk mengelompokkan data berdasarkan satu atau lebih varibel. Fungsi `arrange()` digunakan untuk mengurutkan data berdasarkan variabel. Pengurutan bisa dilakukan dari kecil ke besar atau sebaliknya. Misalnya dalam kasus ini kita ingin mengelompokkan data berdasarkan variabel Country dan sekaligus menghitung jumlah transaksinya dan diurutkan dari besar ke kecil.

```
stockcode85123A %>%
  group_by(Country) %>%
  count() %>%
  arrange(-n)
```

```
## # A tibble: 13 x 2
## # Groups:   Country [13]
##    Country             n
##    <chr>           <int>
##  1 United Kingdom   1097
##  2 EIRE               15
##  3 Netherlands         4
##  4 Cyprus              3
##  5 Spain               3
##  6 Portugal            2
##  7 Australia           1
##  8 Channel Islands     1
##  9 Finland             1
## 10 France              1
## 11 Malta               1
## 12 Singapore           1
## 13 Switzerland         1
```

Bisa kita lihat negara yang paling banyak melakukan transaksi adalah United Kingdom yaitu sebanyak 1097 kali

Sekarang kita akan hitung berapa jumlah transaksi berdasarkan StockCode, maka bisa kita tuliskan seperti ini.

```
retailClean %>%
  group_by(StockCode) %>%
  count() %>%
  arrange(-n)
```

```
## # A tibble: 3,264 x 2
## # Groups:   StockCode [3,264]
##    StockCode     n
##    <chr>     <int>
##  1 85123A     1131
##  2 22423       961
##  3 47566       787
##  4 85099B      704
##  5 84879       664
##  6 20725       633
##  7 21212       584
##  8 22720       562
##  9 22960       515
## 10 22457       512
## # ... with 3,254 more rows
```

Transaksi yang paling banyak adalah untuk StockCode 85123A sebanyak 1131.

Contoh lain, bagaimana kita menghitung jumlah transaksi berdasarkan InvoiceNo.

```
retailClean %>%
  group_by(InvoiceNo) %>%
  count() %>%
  arrange(-n)
```

```
## # A tibble: 8,590 x 2
## # Groups:   InvoiceNo [8,590]
##    InvoiceNo     n
##        <int> <int>
##  1    547063   294
##  2    554098   264
##  3    543040   259
##  4    556484   205
##  5    552039   176
##  6    540372   171
##  7    537224   169
##  8    545901   164
##  9    537781   161
## 10    540247   157
## # ... with 8,580 more rows
```

Bisa dilihat bahwa InvoiceNo 547063 berisi sebanyak 294 transaksi.

Sampling

Fungsi `sample_n()` digunakan untuk mengambil secara acak data, artinya kita bisa mengambil sampel dari data secara acak. Misalnya kita ingin mengambil sebanyak 5 sampel data dari variabel Quantity pada objek UK.

```
sample_n(UK, size = 10)
```

```
##    InvoiceNo StockCode                         Description Quantity
## 1     540542    85123A WHITE HANGING HEART T-LIGHT HOLDER        6
## 2     545588    85123A WHITE HANGING HEART T-LIGHT HOLDER        6
## 3     545578    85123A WHITE HANGING HEART T-LIGHT HOLDER       12
## 4     549998    85123A WHITE HANGING HEART T-LIGHT HOLDER       32
## 5     542231    85123A WHITE HANGING HEART T-LIGHT HOLDER        6
## 6     545085    85123A WHITE HANGING HEART T-LIGHT HOLDER        1
## 7     554492    85123A WHITE HANGING HEART T-LIGHT HOLDER       20
## 8     549716    85123A WHITE HANGING HEART T-LIGHT HOLDER       12
## 9     539450    85123A WHITE HANGING HEART T-LIGHT HOLDER        6
## 10    549262    85123A WHITE HANGING HEART T-LIGHT HOLDER        3
##             InvoiceDate UnitPrice CustomerID        Country
## 1  2011-01-09 15:18:00      2.95      15107 United Kingdom
## 2  2011-03-04 10:03:00      2.95      13382 United Kingdom
## 3  2011-03-03 19:21:00      2.95      13715 United Kingdom
## 4  2011-04-14 08:49:00      2.55      17675 United Kingdom
## 5  2011-01-26 13:40:00      2.95      16714 United Kingdom
## 6  2011-02-28 11:19:00      2.95      15039 United Kingdom
## 7  2011-05-24 13:56:00      2.95      13168 United Kingdom
## 8  2011-04-11 14:43:00      2.95      14628 United Kingdom
## 9  2010-12-17 16:53:00      2.95      15570 United Kingdom
## 10 2011-04-07 12:38:00      2.95      14465 United Kingdom
```

Select

Fungsi `select()` digunakan untuk mengambil satu atau beberapa variabel tertentu yang ada dalam dataset. Sebagai contoh disini kita akan mengambil varibel InvoiceNo, dan Quantity dan tampilkan hanya 6 data teratas.

```
head(select(UK, c(1,4)))
```

```
##   InvoiceNo Quantity
## 1    536365        6
## 2    536373        6
## 3    536375        6
## 4    536390       64
## 5    536394       32
## 6    536396        6
```

Summarise

Fungsi `summarise()` digunakan untuk meringkas beberapa nilai data menjadi sebuah nilai. Dalam prakteknya fungsi ini akan sangat bergunan kalau digabungkan dengan fungsi-fungsi yang lain. Sebagai contoh

dalam kasus ini kita akan menampilkan jumlah traksaksi dari negara UK berdasarkan jumlah Quantity harian. Nilainya kita akan simpan pada objek *UK_daily_retail*

```
UK_daily_retail <- UK %>%
  group_by(InvoiceDate) %>%
  summarise(
    jmlTrans = sum (Quantity)
  )
```

```
## `summarise()` ungrouping output (override with `.groups` argument)
```

```
head(arrange(UK_daily_retail, (-jmlTrans)))
```

```
## # A tibble: 6 x 2
##   InvoiceDate         jmlTrans
##   <dttm>                 <int>
## 1 2011-01-11 12:55:00     1930
## 2 2011-04-18 13:20:00     1930
## 3 2011-01-11 08:43:00     1010
## 4 2011-05-26 19:49:00      608
## 5 2010-12-16 11:07:00      500
## 6 2011-06-02 14:46:00      320
```

```
tail(arrange(UK_daily_retail, (-jmlTrans)))
```

```
## # A tibble: 6 x 2
##   InvoiceDate         jmlTrans
##   <dttm>                 <int>
## 1 2011-05-29 14:03:00        1
## 2 2011-06-01 12:05:00        1
## 3 2011-06-02 11:33:00        1
## 4 2011-06-05 15:46:00        1
## 5 2011-06-15 14:26:00        1
## 6 2011-06-23 19:20:00        1
```

Bisa dilihat bahwa traksaksi paling banyak ada pada tanggal 11-01-2011 dan 18-04-2011 sebanyak 1930 transaksi.

Visualization Analysis

Visualiasi analisis ini adalah bagaimana kita memvisualisasikan hasil Explanatory Data Analysis yang sudah kita lakukan sebelumnya. Dalam kasus ini kita akan memvisualisasikan dengan menggunakan `library ggplot2`

Sebagai contoh kita akan memvisualisasikan hasil dari transaksi harian yang ada pada negara UK yang sebelumnya sudah kita simpan pada objek *UK_daily_retail*

```
UK_daily_retail %>%
  ggplot(aes(x=InvoiceDate, y=jmlTrans)) +
  geom_point() +
  theme_minimal()
```

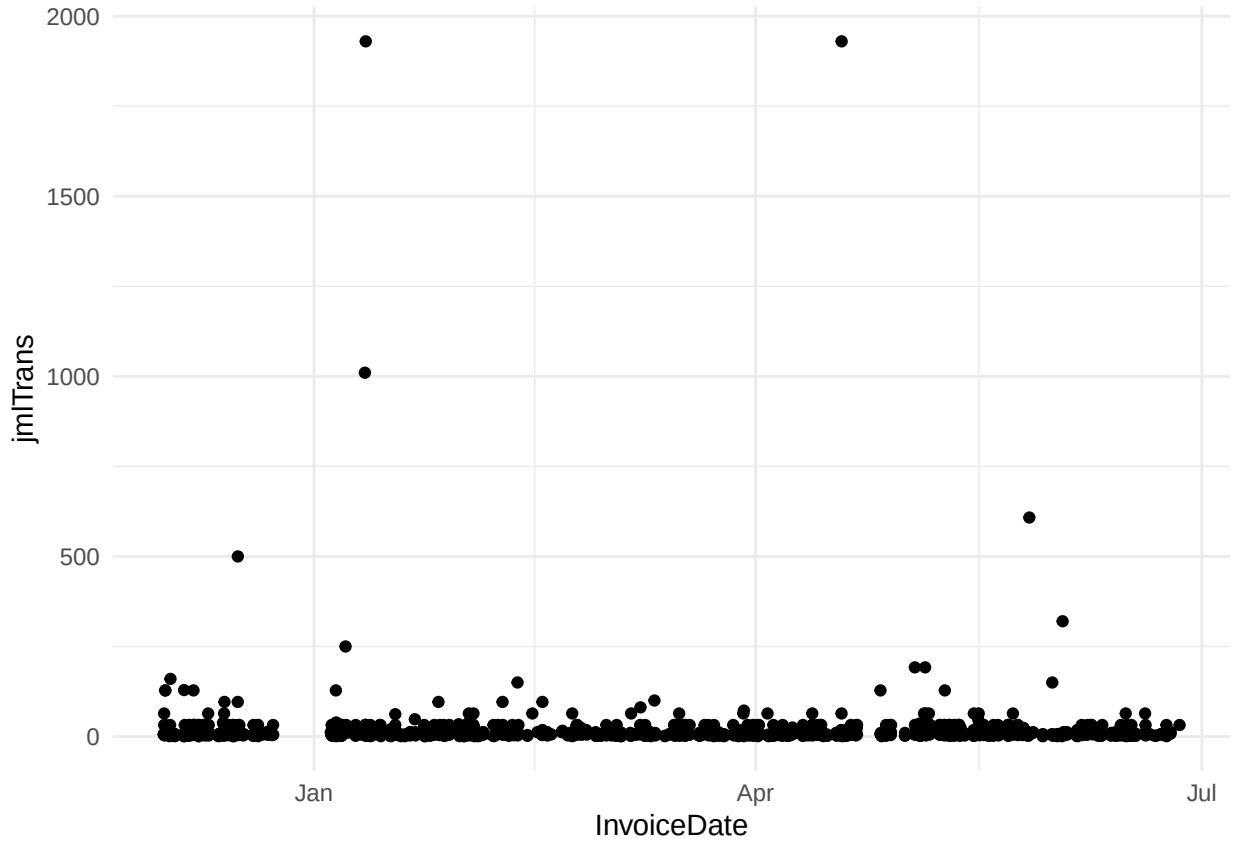

Contoh visualisasi lain yang dilengkapi dengan title dan subtitle

```
UK_daily_retail %>%
  ggplot(aes(x=InvoiceDate, y=jmlTrans)) +
  geom_line(color = "tomato3") +
  labs(
    title = "Transaksi Harian",
    subtitle = "United Kingdom",
    caption = "by: Roni Yunis",
    x = "Bulan",
    y = "Jumlah"
  ) +
  theme_minimal()
```

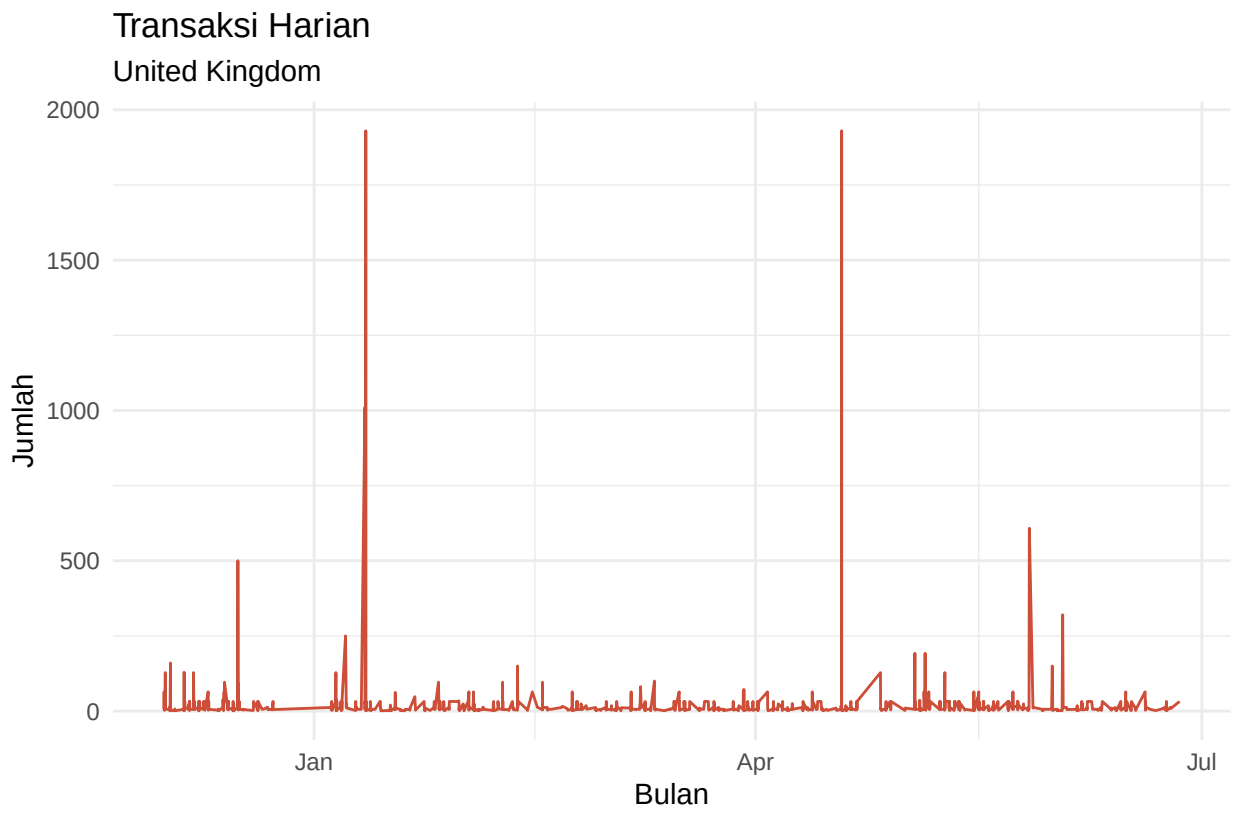

Misalkan kita diminta untuk memvisualisasi transaksi berdasarkan InvoiceDate dan Quantity berdasarkan semua transaksi dengan StockCode = 85123A

```
ggplot(stockcode85123A)+
  aes(x=InvoiceDate, y=Quantity) +
  geom_point (colour = "tomato3") +
  labs(
    title = "Transaksi Harian",
    subtitle = "Stock Code 85123A",
    caption = "by: Roni Yunis",
    x = "Bulan",
    y = "Jumlah"
  ) +
theme_minimal()
```

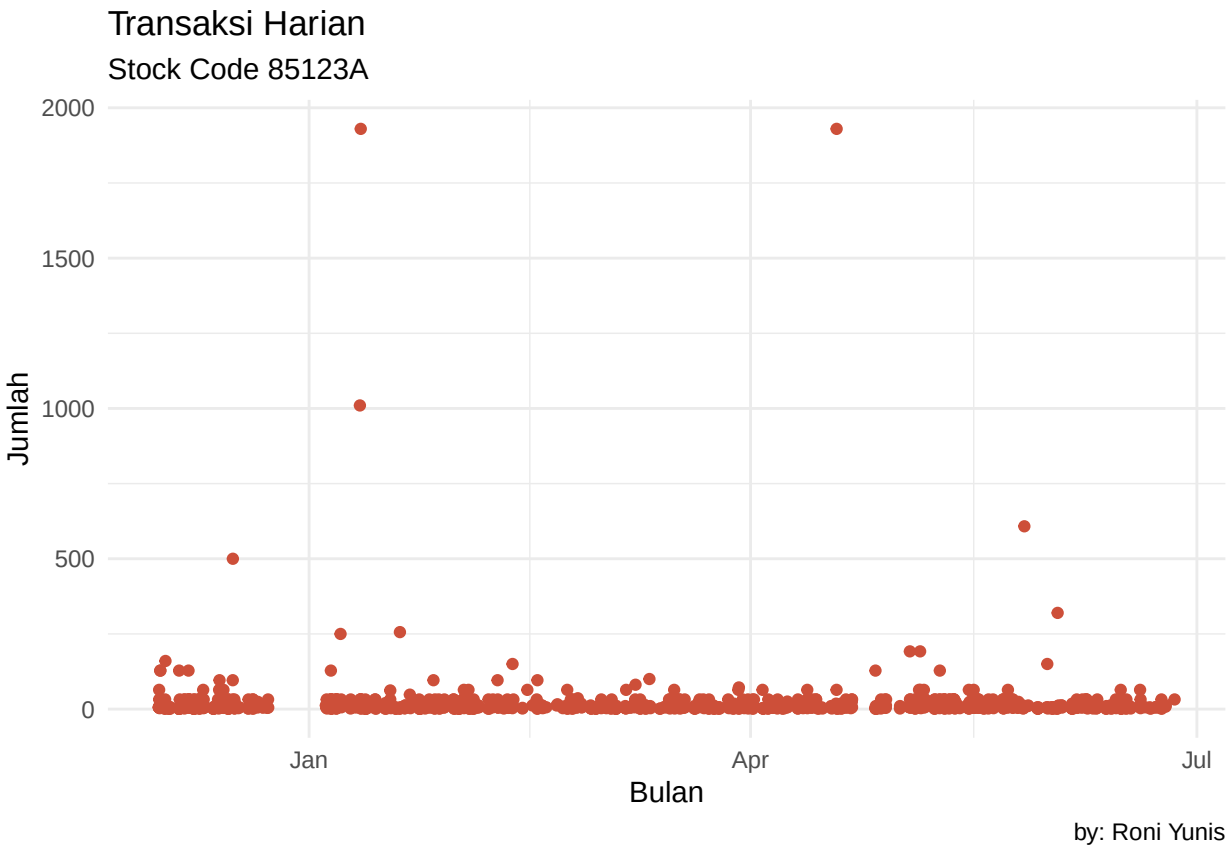
Transaksi Harian
Stock Code 85123A
2000
1500
1000
500
0
Jumlah
Jan
Apr
Jul
Bulan
by: Roni Yunis