# Modul08-Simple Linear Regression

Roni Yunis

3/19/2021

### Load Packages

```
#Split dataset
library (caTools)
#Predicting result visualization
library(ggplot2)
#Import format data xlsx
library(readxl)
```

### Import dataset

```
credit <- read_excel("data/Credit Risk Data.xlsx", sheet = "Base Data")
head(credit)</pre>
```

```
## # A tibble: 6 x 12
    LoanPurpose Checking Savings MonthsCustomer MonthsEmployed Gender
    <chr>
                 <dbl>
                           <dbl>
                                     <dbl>
                                                       <dbl> <chr>
## 1 Small Appl~
                    0
                            739
                                           13
                                                          12 M
                     0
## 2 Furniture
                         1230
                                            25
                                                           0 M
## 3 New Car
                     0
                            389
                                            19
                                                         119 M
## 4 Furniture
                     638
                            347
                                            13
                                                          14 M
## 5 Education
                    963
                            4754
                                            40
                                                          45 M
                    2827
                              0
## 6 Furniture
                                            11
                                                          13 M
## # ... with 6 more variables: MaritalStatus <chr>, Age <dbl>, Housing <chr>,
## # Years <dbl>, Job <chr>, CreditRisk <chr>
```

Melihat dimensi dari data, dengan menggunakan fungsi dim()

```
dim(credit)
```

```
## [1] 425 12
```

Melihat struktur dari data, dengan menggunakan fungsi str()

#### str(credit)

```
## tibble [425 x 12] (S3: tbl_df/tbl/data.frame)
                    : chr [1:425] "Small Appliance" "Furniture" "New Car" "Furniture" ...
    $ LoanPurpose
                    : num [1:425] 0 0 0 638 963 ...
##
   $ Checking
##
   $ Savings
                    : num [1:425] 739 1230 389 347 4754 ...
##
   $ MonthsCustomer: num [1:425] 13 25 19 13 40 11 13 14 37 25 ...
   $ MonthsEmployed: num [1:425] 12 0 119 14 45 13 16 2 9 4 ...
##
   $ Gender
                    : chr [1:425] "M" "M" "M" "M" ...
##
   $ MaritalStatus : chr [1:425] "Single" "Divorced" "Single" "Single" ...
   $ Age
##
                    : num [1:425] 23 32 38 36 31 25 26 27 25 43 ...
                    : chr [1:425] "Own" "Own" "Own" "Own" ...
   $ Housing
##
   $ Years
                    : num [1:425] 3 1 4 2 3 1 3 1 2 1 .
##
   $ Job
                    : chr [1:425] "Unskilled" "Skilled" "Management" "Unskilled" ...
                    : chr [1:425] "Low" "High" "High" "High" ...
##
   $ CreditRisk
```

#Cek data kosong/missing value

#### summary(credit)

```
MonthsCustomer
    LoanPurpose
                            Checking
                                             Savings
                                          Min.
##
    Length: 425
                        Min.
                                     0
                                                       0
                                                           Min.
                                                                   : 5.0
##
    Class : character
                         1st Qu.:
                                     0
                                          1st Qu.:
                                                    228
                                                           1st Qu.:13.0
    Mode :character
                        Median :
                                          Median :
                                                     596
                                                           Median:19.0
                                     0
##
                         Mean
                                : 1048
                                          Mean
                                                  : 1813
                                                           Mean
                                                                   :22.9
##
                         3rd Qu.:
                                          3rd Qu.:
                                                           3rd Qu.:28.0
                                  560
                                                    921
##
                         Max.
                                :19812
                                          Max.
                                                  :19811
                                                           Max.
                                                                   :73.0
##
    MonthsEmployed
                         Gender
                                          MaritalStatus
                                                                    Age
    Min.
           : 0.0
                     Length: 425
                                          Length: 425
##
                                                              Min.
                                                                      :18.0
    1st Qu.: 6.0
##
                     Class : character
                                          Class : character
                                                              1st Qu.:26.0
    Median: 20.0
                     Mode :character
                                          Mode :character
                                                              Median:32.0
##
    Mean
           : 31.9
                                                                      :34.4
                                                              Mean
##
    3rd Qu.: 47.0
                                                              3rd Qu.:41.0
##
           :119.0
                                                                      :73.0
    Max.
                                                              Max.
##
      Housing
                             Years
                                             Job
                                                              CreditRisk
##
    Length: 425
                                         Length: 425
                                                             Length: 425
                         Min.
                                :1.00
##
    Class : character
                         1st Qu.:2.00
                                         Class : character
                                                             Class : character
##
    Mode : character
                         Median:3.00
                                         Mode :character
                                                             Mode :character
##
                        Mean
                                :2.84
##
                         3rd Qu.:4.00
##
                         Max.
                                :4.00
```

Sekarang kita akan mencoba melihat korelasi antara Age (Umur) dengan MonthsEmployed (Bulan Bekerja).

```
#menghitung korelasi antar variabel
korelasi <- cor(credit$Age, credit$MonthsEmployed)
korelasi</pre>
```

#### ## [1] 0.3067985

Koefisien korelasi mengukur tingkat hubungan antara dua variabel x dan y. Nilainya berkisar antara -1 (korelasi negatif sempurna: ketika x meningkat, y menurun) dan +1 (korelasi positif sempurna: ketika x meningkat, y meningkat).

Nilai yang mendekati 0 menunjukkan hubungan yang lemah antara variabel. Korelasi yang rendah (-0.2 < x < 0.2) mungkin menunjukkan bahwa banyak variasi dari variabel hasil (y) tidak dijelaskan oleh prediktor (x). Dalam kasus seperti itu, kita mungkin harus mencari variabel prediktor yang lebih baik.

Dalam contoh ini, koefisien korelasinya tidak terlalu besar yaitu 0,31, jadi kita bisa melanjutkan dengan membangun model linier y sebagai fungsi dari x.

#### Bagi dataset kedalam data training dan data testing

```
splitdata <- sample.split(credit$MonthsEmployed, SplitRatio = 0.7)
trainingset <- subset(credit, splitdata == TRUE)
testingset <- subset(credit, splitdata == FALSE)</pre>
```

#### Lakukan liner regresi sederhana pada data training

Berdasarkan output diatas bisa dijelaskan bahwa: Persamaan regresi linernya adalah Months Employed = 5.91 + 0.75\*Age

Sebelum menggunakan rumus ini untuk memprediksi Bulan Bekerja di masa mendatang, Anda harus memastikan bahwa model ini signifikan secara statistik, yaitu: Ada hubungan yang signifikan secara statistik antara prediktor dan variabel hasil, kita akan memeriksa kualitas model regresi linier.

## Summary dari model

```
summary(lm.r)
```

```
##
## lm(formula = MonthsEmployed ~ Age, data = trainingset)
##
## Residuals:
##
      Min
               1Q Median
                               3Q
                                      Max
## -63.322 -21.180 -7.525 16.500 98.467
##
## Coefficients:
##
              Estimate Std. Error t value Pr(>|t|)
## (Intercept) -2.3543
                           5.9568 -0.395
                                             0.693
## Age
                0.9951
                           0.1648
                                    6.037 4.7e-09 ***
```


```
## ---
## Signif. codes: 0 '***' 0.001 '**' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 30.92 on 296 degrees of freedom
## Multiple R-squared: 0.1096, Adjusted R-squared: 0.1066
## F-statistic: 36.44 on 1 and 296 DF, p-value: 4.704e-09
```

### Prediksi model regresi dengan data testing

```
yprediksi <- predict(lm.r, newdata = testingset)</pre>
```

### Visualasi hasil data training

## Age vs Months Employed (Data Training)



## Visualasi hasil data testing

## Age vs Months Employed (Data Testing)

